



Módulo 7

Projeto Final

Extensão Data Engineering

- Módulo final da extensão Data Science
- Turma dividida em grupos de no máximo 5 pessoas
- Cada grupo resolverá um problema no contexto de aplicação da In Loco Media
 - A solução do problema deve ter o formato de um Jupyter Notebook na linguagem Python, contendo o código e os elementos gráficos correspondentes
- Serão avaliados itens técnicos, de comunicação e organizacionais

- **Técnicos:**
 - Uso de conceitos e ferramentas apresentados durante os módulos anteriores para configuração do ambiente cloud e desenvolvimento de soluções funcionais
- **Organizacionais:**
 - Participação nos encontros, trabalho em equipe, conformidade aos requisitos do problema

- **Comunicação:**
 - Apresentação dos resultados desenvolvidos pelo grupo durante o projeto como uma apresentação de no máximo 30 min, descrevendo a solução desenvolvida por meio de um conjunto de slides e demonstrando em tempo real sua funcionalidade.
 - 14 e 15 de setembro
 - Ambiente colaborativo, Slack: <https://bit.ly/2N9KnDv>

1. Use as credenciais no ambiente AWS para criar a infraestrutura de cluster necessária para o projeto
 - a. Um único cluster pode ser instalado com Dask e Spark
2. Use Jupyterhub e Jupyter notebooks para o desenvolvimento
3. Instale de antemão todas as dependências (e.g. bibliotecas de geolocalização)
 - a. Dica: no caso do EMR, uma vez que todas as suas dependências estiverem instaladas, criem um arquivo bash para executar a instalação dessas dependências.
 - i. Dúvida: <https://ryantutorials.net/bash-scripting-tutorial/bash-script.php>
4. Comece o desenvolvimento usando pequenas amostras dos dados, sem preocupação inicial com volumes

1. Cada cluster terá **uma quantidade de horas disponível** para cada usuário (a.k.a cada grupo).
2. Lembre-se de utilizar o **S3** para armazenar dados e resultados de processamentos
 - a. Lembre-se-2, as instâncias são efêmeras (no caso do EMR/Spark), ou seja, resultados podem ser perdidos.
 - b. Sejam organizados, se por algum motivo vocês subscreverem (acidentalmente) algum arquivo, não teremos como recuperar em tempo hábil.
 - i. **Trabalhem dentro dos seus buckets!!**
3. Quando criarem uma instância (caso do Dask) lembrem de:
 - a. **Colocar um nome na instância identificando o nome do seu grupo. Instâncias sem nome serão apagadas!**
 - b. Sempre que não estiverem usando as instâncias, lembrem de desligar.
4. Criem clusters com no máximo 4 instâncias (1 master 3 slaves)
 - a. m4.large
 - b. Lembre-se, faça pequenos processamentos antes de processar grandes bases.

1. Desempenho das campanhas publicitárias
2. Desempenho dos estabelecimentos
3. Correlação entre interações e visitas
4. Atratividade dos anúncios
5. Perfil de interação com de anúncios
6. Perfil de visita aos estabelecimentos
7. Recomendação em tempo real



1. Desempenho das campanhas publicitárias
 - a. Grupo:
2. Desempenho dos estabelecimentos
 - a. Grupo:
3. Correlação entre interações e visitas
 - a. Grupo:
4. Atratividade dos anúncios
 - a. Grupo:



5. Perfil de interação com de anúncios
 - a. Grupo:
6. Perfil de visita aos estabelecimentos
 - a. Grupo:
7. Recomendação em tempo real
 - a. Grupo:

Desempenho das campanhas



- O *click-through rate* (CTR) de uma campanha é a razão entre o número de anúncios que foram clicados e o número de anúncios que foram visualizados
 - Exemplo: campanha A tem um único anúncio, visualizado 10.000 vezes e clicado 185 vezes.
 $CTR = 185/10.000$ ou 1,85%
- Os dados disponibilizados indicam ações (cliques ou visualizações) feitas para cada anúncio; uma campanha pode ter mais de um anúncio
- O CTR é uma métrica importante para avaliar a atratividade de uma campanha para determinado público alvo

Desempenho das campanhas



- Para os dados estáticos disponibilizados:
 - Com a plataforma Dask, crie um cluster com um master e dois workers, persista os dados em memória e crie rotinas que calculam o **CTR para cada campanha**, agregando por mês e pelo período completo;
 - Crie gráficos para indicar as **campanhas com melhor CTR** em cada mês e para o período completo;

Desempenho de estabelecimentos



- Os anúncios de uma campanha são relativos a estabelecimentos, listados nos dados disponibilizados contendo sua localização geográfica
- Uma visita de um cliente a um estabelecimento é definida como um registro de localização daquele cliente a menos de 50 metros da localização do estabelecimento
- Saber quais estabelecimentos recebem mais visitas é relevante na avaliação de retorno de campanhas

Desempenho de estabelecimentos



- Para os dados estáticos disponibilizados:
 - Com a plataforma Spark, crie um cluster com um master e dois workers, persista os dados em memória e crie rotinas que calculam para cada registro de localização do um cliente **se houve visita** a um estabelecimento. Agregue os número de visitas a cada estabelecimento **por mês e pelo período completo**;
 - Crie gráficos para indicar os estabelecimentos com mais visitas em cada mês e para o período completo;

Correlação entre interações e visitas



- A geração de uma visita a um estabelecimento a partir de uma interação com um anúncio é uma métrica de importância para a avaliação de sua eficácia
- A correlação forte entre interações e visitas sugere que o anúncio tem poder de convencimento significativo
- A correlação é considerada quando um registro de localização do usuário é feito a menos de 50m do estabelecimento relacionado ao anúncio, em até 6 horas depois da interação ter acontecido

Correlação entre interações e visitas



- Para os dados estáticos disponibilizados:
 - Com a plataforma Dask, crie um cluster com um master e dois workers, persista os dados em memória e crie rotinas que calculam para cada estabelecimento a razão entre o número de visitas relacionadas a interações e o número total de visitas, agregando por mês e pelo período completo;
 - Crie gráficos para indicar por mês os estabelecimentos com maior correlação entre interações e visitas;

Atratividade de anúncios



- Um potencial cliente pode interagir com os anúncios de uma campanha por meio de visualização e cliques
- Cada anúncio pertence a uma categoria, que agrupa áreas de atuação similares, tais como games, restaurantes e hotéis
- O desempenho das categorias de anúncios ao longo do dia pode ser medido pela quantidade de interações registradas



Atratividade de anúncios



- Para os dados estáticos disponibilizados:
 - Com a plataforma Spark, crie um cluster com um master e dois workers, persista os dados em memória e crie rotinas que calculam para cada hora do dia a **quantidade de interações** registradas para cada categoria de anúncios;
 - Crie gráficos para indicar a **distribuição de interações** durante as horas do dia nas categorias de anúncios, agregando por mês e pelo período completo;

Perfil de interação com anúncios



- A interação de potenciais clientes com anúncios de campanhas publicitárias cria um histórico que pode indicar os interesses pessoais
- Uma predominância de interação com determinadas categorias de anúncios, em determinadas horas do dia, podem indicar preferências e orientar futuras ofertas de produtos e serviços
- A identificação deste perfil, relacionado ao período do dia, é valioso para aumentar a eficiência das campanhas



Perfil de interação com anúncios



- Para os dados estáticos disponibilizados:
 - Com a plataforma Dask, crie um cluster com um master e dois workers, persista os dados em memória e crie rotinas que calculam para cada usuário as distribuições de interações com categorias de anúncio período do dia. Crie também uma tabela com a categoria preferida de cada usuário em cada período;
 - Crie gráficos para ilustrar, para alguns usuários, a distribuição de frequências das categorias ao longo do dia e as categorias preferidas;

Perfil de visita aos estabelecimentos



- O padrão de visitas de um potencial cliente aos estabelecimentos conveniados cria um histórico que pode indicar os interesses pessoais
- Uma predominância de interação com determinadas categorias de estabelecimentos, em determinados dias da semana, podem indicar preferências e orientar futuras ofertas de produtos e serviços
- A identificação deste perfil, relacionado ao período da semana, é valioso para aumentar a eficiência das campanhas



Perfil de visita aos estabelecimentos



- Para os dados estáticos disponibilizados:
 - Com a plataforma Spark, crie um cluster com um master e dois workers, persista os dados em memória e crie rotinas que calculam para cada usuário as distribuições de visitas a categorias de estabelecimentos por dia da semana. Crie também uma tabela com a categoria preferida de cada usuário em cada dia da semana;
 - Crie gráficos para ilustrar, para alguns usuários, a distribuição de frequências das categorias ao longo da semana e as categorias preferidas;

Recomendação em tempo real



- Os registros de posição em tempo real recebidos pela plataforma permitem acompanhar o deslocamento de clientes potenciais dos estabelecimentos conveniados
- Ao calcular em tempo real a distância de cada cliente para os estabelecimentos é possível mostrar de ofertas fisicamente próximas, aumentando a conveniência do cliente
- Ofertas em tempo real baseadas em geolocalização criam novas oportunidades para campanhas publicitárias

Recomendação em tempo real



- Para os dados **dinâmicos** disponibilizados:
 - Com a plataforma Spark, crie um cluster com um master e dois workers, conecte-se ao serviço de mensagens que envia as posições dos clientes em tempo real e crie rotinas que calculam a distância de cada cliente para cada um dos estabelecimentos. Com base nisso, crie uma rotina que sugira em tempo real anúncios de estabelecimentos dos quais o cliente está se aproximando;
 - Crie mapas georeferenciados para ilustrar, para alguns usuários, quando a aproximação de um estabelecimento resultou em uma sugestão de anúncio;

Sobre Spark e Dask



- Spark (EMR)
 - Ver slides do último módulo
- Dask (SCHEDULER)
 - Para instalar: <http://dask.pydata.org/en/latest/install.html>
 - Instalar o Bokeh : <https://bokeh.pydata.org/en/latest/docs/installation.html>
 - Gerar uma imagem.
 - Gerar novas instâncias a partir dessa instância.
 - Uma delas será o scheduler e as demais workers

Sobre Spark e Dask



- Dask-scheduler

```
distributed.scheduler - INFO - -----  
distributed.scheduler - INFO - Scheduler at:  tcp://172.31.34.3:8786  
distributed.scheduler - INFO - Local Directory:  /tmp/scheduler-f2wvtl5w  
distributed.scheduler - INFO - -----  
distributed.scheduler - INFO - Register tcp://172.31.28.205:41188  
distributed.scheduler - INFO - Starting worker compute stream, tcp://172.31.28.205:41188  
distributed.scheduler - INFO - Register tcp://172.31.25.47:41100  
distributed.scheduler - INFO - Starting worker compute stream, tcp://172.31.25.47:41100
```

- Dask-work
 - dask-work 172.31.34.3:8786 (IP do scheduler)
- Geral:
 - Jupiter hub pode ser instalado da mesma forma que no EMR
 - Pacotes específicos também precisam ser instalados



C.E.S.A.R

inovação
é a gente

